

# 1. TỔNG QUAN BÀI TOÁN & TÌNH HÌNH NGHIÊN CỨU

Bài toán TTS đã có sự dịch chuyển trọng tâm rõ rệt trong thập kỷ qua:

- **Giai đoạn trước:** Tập trung vào **Intelligibility** (Độ dễ hiểu). Mục tiêu là máy phát âm đúng từ, người nghe hiểu được nội dung.
- **Giai đoạn hiện tại:** Tập trung vào **Naturalness** (Độ tự nhiên) và **Expressiveness** (Độ biểu cảm). Mục tiêu là máy nói có cảm xúc, ngắt nghỉ đúng ngữ cảnh, sao chép (clone) giọng nói của bất kỳ ai (Zero-shot).

Nghiên cứu hiện tại chia làm 3 hướng tiếp cận chính (Levels), đi từ các luật cơ bản đến mô hình Generative AI phức tạp.

## 2. PHÂN TÍCH 3 HƯỚNG TRIỂN KHAI (LEVELS)

### Level 1: Statistical Parametric & Concatenative (Cổ điển)

- **Cơ chế:** Cắt ghép các đoạn âm thanh nhỏ (từ, âm tiết) từ database hoặc sinh tham số dựa trên mô hình thống kê (HMM).
- **Ưu điểm:**
  - Tài nguyên tính toán cực thấp (chạy tốt trên chip nhúng, offline).
  - Độ trễ (Latency) cực thấp, phản hồi tức thì.
  - Kiểm soát chính xác cách phát âm từng từ.
- **Nhược điểm:**
  - Giọng vô hồn, đứt gãy, nghe giống Robot.
  - Không thể thay đổi ngữ điệu hay cảm xúc.
- **Trường hợp sử dụng (Use Case):**
  - Máy đọc màn hình cho người khiếm thị (TalkBack, NVDA) - nơi tốc độ ưu tiên hơn cảm xúc.
  - Thiết bị IoT giá rẻ, đồ chơi trẻ em.
  - Hệ thống thông báo công cộng cố định.

### Level 2: Neural TTS (Deep Learning End-to-End)

- **Cơ chế:** Sử dụng Deep Learning (Tacotron 2, FastSpeech) map trực tiếp Text  $\rightarrow$  Mel-spectrogram  $\rightarrow$  Waveform.
- **Ưu điểm:**
  - Chất lượng âm thanh tự nhiên, mượt mà (đạt mức Mean Opinion Score - MOS cao).
  - Ổn định, ít lỗi đọc sai.
- **Nhược điểm:**
  - Phụ thuộc dữ liệu: Cần dataset sạch, lớn (vài chục giờ) của một người cụ thể (Single-speaker).
  - Khó mở rộng: Muốn có giọng mới phải thu âm và train/fine-tune lại từ đầu, tốn kém.
- **Trường hợp sử dụng (Use Case):**
  - Trợ lý ảo (Virtual Assistants) như Google Assistant, Siri.
  - Sách nói (Audiobooks), báo nói.
  - Tổng đài chăm sóc khách hàng tự động (Call Center).

### Level 3: Generative AI / Zero-shot TTS (LLM-based)

- **Cơ chế:** Coi TTS là bài toán mô hình ngôn ngữ (Language Modeling). Mô hình (VALL-E, XTTS) dự đoán token âm thanh dựa trên text và mẫu giọng nói (prompt).
- **Ưu điểm:**
  - **Zero-shot/Few-shot:** Sao chép giọng (Voice Cloning) chỉ với 3-5 giây âm thanh mẫu.
  - Đa dạng: Giữ được cảm xúc, tiếng thở, noise môi trường, ngữ điệu phức tạp.
- **Nhược điểm:**
  - Tài nguyên lớn: Tốn GPU khủng để chạy inference.
  - Độ trễ cao: Khó ứng dụng cho hội thoại thời gian thực ngay lập tức.
  - Tính ổn định thấp: Dễ bị ảo giác (hallucination) - đọc thừa, thiếu từ, cười nói ngẫu nhiên.
- **Trường hợp sử dụng (Use Case):**
  - Lồng tiếng phim tự động (Dubbing).
  - Sáng tạo nội dung (Content Creator), Podcast AI.
  - NPC trong Game cần hội thoại động.

## 3. CHIẾN LƯỢC TỐI ƯU HÓA PIPELINE

Để khắc phục nhược điểm của từng Level, các nghiên cứu hiện tại (SOTA) không dùng đơn lẻ một mô hình mà thiết kế **Pipeline lai (Hybrid)** và áp dụng các kỹ thuật tối ưu sau:

### 3.1. Tối ưu hóa Tốc độ (Giảm Latency cho Level 2 & 3)

- **Vấn đề:** Các mô hình cũ (Tacotron, VALL-E gốc) dùng cơ chế **Autoregressive** (Tự hồi quy) - sinh âm thanh tuần tự từng chút một  $\rightarrow$  Rất chậm.
- **Giải pháp Pipeline:** Chuyển sang kiến trúc **Non-Autoregressive** (Song song hóa).
  - Ví dụ: **FastSpeech 2** hoặc **VITS**.
  - **Cách làm:** Mô hình dự đoán trước thời lượng (duration) của toàn bộ câu, sau đó sinh song song tất cả các khung âm thanh cùng lúc.
  - **Kết quả:** Tốc độ inference tăng gấp hàng trăm lần, cho phép Level 2 chạy real-time mượt mà.

### 3.2. Tối ưu hóa Tài nguyên & Chất lượng âm thanh (Vocoder)

- **Vấn đề:** WaveNet (cũ) nghe hay nhưng quá nặng. Griffin-Lim (cổ điển) nhẹ nhưng nghe tệ.
- **Giải pháp Pipeline:** Sử dụng **GAN-based Vocoder** (như **HiFi-GAN**).
- **Cách làm:** Dùng mạng đối nghịch (GAN) để training. Generator cố tạo âm thanh giống thật, Discriminator cố soi lỗi.
- **Kết quả:** HiFi-GAN tạo âm thanh chất lượng cao (gần như bản thu gốc) nhưng tốc độ cực nhanh và tốn ít CPU/GPU, giải quyết bài toán hiệu năng.

### 3.3. Tối ưu hóa Dữ liệu & Cá nhân hóa (Khắc phục nhược điểm Level 2)

- **Vấn đề:** Level 2 cần quá nhiều dữ liệu thu âm tốn kém. Level 3 thì không ổn định.
- **Giải pháp Pipeline:** **Transfer Learning (Học chuyển giao) & Speaker Adaptation**.
- **Cách làm:**
  1. **Pre-training:** Train một model gốc cực lớn trên 10.000 giờ dữ liệu đa ngôn ngữ/đa người nói (tận dụng kiến trúc Level 3).

2. **Fine-tuning:** Đóng băng các lớp đầu, chỉ train lại lớp cuối với 5-10 phút dữ liệu của user mục tiêu.

- **Kết quả:** Giảm yêu cầu dữ liệu từ hàng chục giờ xuống vài phút. Giữ được độ ổn định của Level 2 nhưng có tính linh hoạt gần bằng Level 3.

### 3.4. Tối ưu hóa sự ổn định (Khắc phục "Ảo giác" Level 3)

- **Vấn đề:** Generative AI hay đọc sai, nuốt chữ.
- **Giải pháp Pipeline:** Kết hợp **Duration Predictor** (từ Level 2) vào Level 3.
- **Cách làm:** Thay vì để AI tự do sinh token, pipeline ép buộc AI tuân thủ thông tin về "thời lượng phát âm" (alignment) của từng từ.
- **Kết quả:** Loại bỏ hiện tượng đọc lặp, đọc thiếu, đảm bảo nội dung chính xác tuyệt đối trong khi vẫn giữ được chất giọng clone.

## 4. ĐẠO ĐỨC NGHIÊN CỨU

- **Vấn đề:** Deepfake voice, giả mạo danh tính.
- **Giải pháp bắt buộc:** Pipeline đầu ra phải đi qua module **Audio Watermarking**. Nhúng tín hiệu ẩn vào phổ âm thanh để định danh sản phẩm của AI.